# 谛听 · 设备预测性维护智能体平台

> 项目代号：Diting（谛听） —— "设备在低语，智能体负责翻译。"
> 应用主体：雅迪电动车集团公司（电动车销量持续第一，全球近 20 个生产基地）及其上下游供应商公司
> 演进目标：预留迁移至其他生产集团（如汽车制造） 文档基线：v1.0 方案基线（Ph0） | 编制日期：2026-10-21 | 状态：待评审确认

---

## 0. 一句话定位

不是再做一个"更准的故障预测模型"，而是把 ISO 13374 的六功能块（DA→DM→SD→HA→PA→AG）用 Agent Harness 工程贯通，交付一个可审计、可降级、可回滚、带排产与备件约束的维护决策系统。

原文的判断我们完全接受并写进方案首页：

> 预测性维护的终点不是"预测得更准"，是"决策得更优"。

但原文停在"装配顺序"，本方案要把它变成可招标、可验收、可审计的工程基线。

---

## 1. 与原文（5 个开源项目 + 五层路线）的关系

| 原文 | 本方案处理 | 说明 |
|---|---|---|
| 五层装配图（数据底座→诊断大脑→交互入口→决策闭环→边缘落地） | 采纳为"能力分层"，但不作为交付顺序 | 交付顺序见 `docs/10`，按 Gate 推进 |
| Open supOS（L1 工业数据底座） | 采纳为参考实现，不锁定 | 保留 Neuron / eKuiper / 自研适配三条替代路径 |
| LimiX（L2 结构化数据模型） | 采纳为候选，附许可证风险与替代方案 | LimiX-2 权重非商用，商用需授权或替换 |
| MCP 预测性维护服务端（L3 交互入口） | 采纳协议形态，工具自研 | 只借鉴 DSP 管线与 ISO 10816/20816 判据，不直接依赖 |
| 四角色虚拟专家会诊（L4 决策闭环） | 采纳并升级：增加独立 Evaluator | 防止"四个角色自说自话" |
| OpenClaw（L5 边缘） | 仅限 POC，生产封装为标准 API | 与原文结论一致：让爱折腾的待在原型层 |
| 上线验收清单（6 项） | 扩展为 6 大类 42 项 | 见 `docs/11` |

---

## 2. 方法论骨架（四层方法，互不替代）

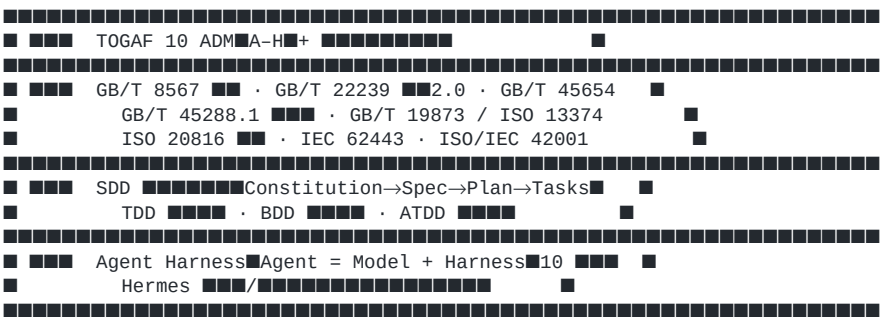


---

## 3. 文档清单与阅读路径

### 3.1 决策者路径（30 分钟）

`docs/00` → `docs/01` → `docs/10` → `docs/11`

### 3.2 架构师路径（2 小时）

`docs/03` → `docs/04` → `docs/05` → `docs/06` → `docs/07`

### 3.3 研发/测试路径

`specs/constitution.md` → `specs/001-*/spec.md` → `docs/08` → `docs/09`

### 3.4 全量清单

| 编号 | 文档 | 主要依据 | 状态 |
|---|---|---|---|
| — | `README.md` | — | 已出 |
| 00 | `docs/00_[redacted].md` | TOGAF 预备阶段 | 已出 |
| 01 | `docs/01_[redacted].md` | TOGAF A / GB/T 8567 可行性分析 | 已出 |
| 02 | `docs/02_[redacted].md` | GB/T 8567-2006 / ISO 29148 / EARS | 已出 |
| 03 | `docs/03_[redacted].md` | TOGAF B/C/D / 4A / C4 | 已出 |
| 04 | `docs/04_[redacted].md` | ISO 13374 / ISO 20816 / OPC UA | 已出 |
| 05 | `docs/05_[redacted]Harness[redacted].md` | Agent Harness 10 组件 / Hermes | 已出 |
| 06 | `docs/06_[redacted].md` | MCP / OPC UA / REST / 事件 | 已出 |
| 07 | `docs/07_[redacted]AI[redacted].md` | 等保2.0 / IEC 62443 / GB/T 45654 / 42001 | 已出 |
| 08 | `docs/08_[redacted].md` | TDD / BDD / ATDD / 模型评测 | 已出 |
| 09 | `docs/09_DevOps[redacted].md` | Harness.io / GitOps / 质量门禁 | 已出 |
| 10 | `docs/10_[redacted].md` | TOGAF E/F / 敏捷-阶段混合 | 已出 |
| 11 | `docs/11_[redacted].md` | 原文清单扩展 / GB/T 8567 验收 | 已出 |
| 12 | `docs/12_[redacted].md` | 全标准映射 | 已出 |
| S0 | `specs/constitution.md` | SDD 项目宪法 | 已出 |
| S1 | `specs/001-[redacted]/spec.md` | SDD / EARS | 已出 |
| S2 | `specs/002-[redacted]/spec.md` | SDD / EARS | 已出 |

| 编号 | 文档 | 主要依据 | 状态 |
| --- | --- | --- | --- |
| S3 | specs/003-■■■■■■/spec.md | SDD / EARS | 已出 |
| — | index.html | 可视化总览（汇报用） | v0.1 |
| 13 | docs/13_■■■■■■■■■■.md | 自我审查 + 优化主线 + D11 – D22 | v1.0 新增 |
| 14 | docs/14_■■■■■■■■■■■■.md | 集团场景 / 多租户 / 联邦 / 供应商 / 行业包 | v1.0 新增 |
| 15 | docs/15_DDD■■■■■CQRS■■.md | DDD / 事件驱动 / CQRS / GraphQL / Saga | v1.0 新增 |
| 16 | docs/16_■■■■■■■■■■■■■.md | Rust/Go/Java/Python + 集群实盘适配 | v1.0 新增 |
| 17 | docs/17_■■■■■■ADR.md | PG / TiDB / TDengine 三分法（ADR-017） | v1.0 新增 |
| 18 | docs/18_K8s■■■■■TiKV■■■■.md | 五层取证 · 根因树 · 修复与验证 | v1.1 新增 |
| 19 | docs/19_■■■■■■■■■■■■.md | Litestar+Granian · 多级缓存 · 实测基准 | v1.1 新增 |
| 20 | docs/20_■■■■ADR_StatefulSet■■■PV.md | Deployment→StatefulSet · 200Gi 本地 PV · 3T 规划 | v1.2 新增 |
| — | index-v2.html | v1.0 评分与优化总览（汇报用） | v1.0 新增 |

---

## 3.5 v1.0 关键变更摘要

| 变更 | 内容 | 依据 |
| --- | --- | --- |
| 场景 | 单厂 → 雅迪集团 20 基地 + 供应商 | docs/14 |
| 建模 | 技术分层 → 8 个限界上下文 + 聚合 + 领域事件 | docs/15 |
| 通信 | 同步 REST 为主 → 事件优先（Pulsar）+ 同步为辅 | docs/15、16 |
| 读写 | 一套库 → CQRS 命令侧/查询侧分离 | docs/15 |
| 查询 | REST 分页 → GraphQL BFF（REST/MCP 并存） | docs/15 |
| 语言 | Python 为主 → Rust/Go/Java/Python 分区 | docs/16 |
| 基础设施 | 自建中间件 → 复用存量（Pulsar/TiDB +TiFlash/Milvus/Nebula/Nacos/LiteLLM/Grafana） | docs/16（实盘盘点） |
| 部署 | 单集群 → 中心集群 + 20 基地边缘（Rancher/Fleet 纳管） | docs/14、16 |

## 3.6 集群实盘结论（docs/16）

`10.167.2.175` = k8s-master（16C/126Gi），`10.167.2.176` = k8s-worker1（64C/126Gi），K8s v1.28.2，Rancher + Fleet + Istio 已装，docker 26.1.4，实际 CPU 用量仅 2 – 10%。

已有可复用：Pulsar、TiDB+TiFlash、Milvus、NebulaGraph、CockroachDB、Redis、Nacos、LiteLLM、Ollama、Prometheus/Grafana/Loki、NFS provisioner。 必须新建：TDengine（时序）、本项目服务。关系库按 D23 复用 TiDB（见 docs/17 §8），不再新建 PG。 两个风险：该集群承载教学/实验业务，须强隔离；master 根分区仅余 15G，波形不能放。

### 3.7 TiKV OOM 已修复（docs/18）

不是单一 OOM，而是五因一链：节点内存超卖（limit 总和 157% – 203%）→ load-testing 无配额 → kubelet 驱逐 Burstable Pod → PD 先崩 → TiKV 退出时腾 leader 超时 → SIGKILL(137)。

已执行 9 项修复：TiKV request 1Gi→2Gi、grace 30s→300s、PD limit 512Mi→2Gi、TiFlash 从"无限制"→16Gi、load-testing 加配额、新增 `pdm-data-critical` 优先级类、TiFlash 改 Recreate 策略。验证：8 个 Pod 全部 Running，TiDB v8.5.8 健康。

### 3.9 当前运行态（已在集群内跑通）

| 项 | 状态 |
|---|---|
| TiDB 集群 | PD 3/3（StatefulSet） · TiKV 3/3（StatefulSet，200Gi/副本） · TiDB 2/2 · TiFlash 1/1 |
| 存储 | 7 个本地 PV 全部 Bound：TiKV 200Gi×3、PD 20Gi×3、TiFlash 100Gi（worker1 `/home` 3T 中划出 760Gi） |
| 数据库 | `pdm` 库 16 张表已建；应用账号 `pdm_diag` 可读写、DDL 被拒 |
| 诊断服务 | `pdm-prod/python-diagnosis` 2 副本 Running，镜像 `10.167.2.175:30500/pdm/python-diagnosis:0.1.0` |
| 访问入口 | `http://10.167.2.175:32231` + Host `pdm-api.10.167.2.175.nip.io` |
| 实测响应 | `hi=59.45, level=orange, degraded=false`，五维分解齐全，每条带证据 |
| 缓存 | L1 命中正常；L2 已接 Redis（db 3），`l2_enabled=true`，键 `pdm:diag:*` 已写入 |

### 3.8 文档导出（Word / PDF）

全部 Markdown 已生成双格式，位于 `export/`：

```
export/
■■■ docx/   30 ■ .docx■■■■■■■■■■■■■■■■■
■■■ pdf/    30 ■ .pdf■A4■■■■■■■■■■■■■
```

重新生成：`cd impl && .venv/Scripts/python.exe tools/md_export.py`

---

## 4. 需要你拍板的 22 个决策点

> D1 – D10 为基础决策点，D11 – D22 为 v1.0 新增（雅迪集团化场景 + 多语言 + 真实集群，定义见 `docs/13 §6`）。逐条给了默认建议，你只需回复"采纳/改成X"。

| # | 决策点 | 选项 | 默认建议 |
|---|---|---|---|
| D1 | 首期场景 | ①单台关键旋转设备（电机/风机/泵）②整线 ③全厂 | ① 1 台关键设备 + 3 类传感器 |
| D2 | 数据是否出厂 | ①完全不出厂（边缘）②特征值出厂 ③原始波形上云 | ② 特征值 + 报警事件出厂，原始波形留厂 |
| D3 | 设备接入方式 | ①直接读 PLC ②经 SCADA/OPC UA 网关 ③加装无线传感器 | ②为主 + ③补盲 |
| D4 | 诊断模型路线 | ①LimiX 结构化模型 ②经典特征+树模型 ③时序基础模型 | ② 先做基线，①/③ 做挑战者 |
| D5 | 大模型部署 | ①公有云 API ②私有化开源模型 ③混合 | ③ 混合：敏感数据本地小模型，规划推理走私有化 |
| D6 | 写操作边界 | ①只读建议 ②可建工单 ③可下备件采购单 | ①→② 分期放开，③ 永不自动 |
| D7 | 部署形态 | ①厂内 K8s ②边缘 K3s + 中心 ③纯边缘 | ② 云边协同 |
| D8 | 与现有系统 | ①EAM/CMMS 对接 ②MES 对接 ③两者 | ③ 但先只做 EAM 单向 |
| D9 | 合规等级 | 等保二级 / 三级 | 三级（含工控区隔离） |
| D10 | 首期预算与周期 | — | 16 周 / 6 人核心团队 |

### 4.1 v1.0 新增决策点 D11 – D22

| # | 决策点 | 默认建议 |
|---|---|---|
| D11 | 雅迪首期范围 | 集团总部 + 2 基地（需验证联邦） |
| D12 | 20 个基地口径 | 按国内 12 + 海外 8 分域设计，待确认 |
| D13 | 供应商接入模式 | 数据上报起步，入驻工单二期 |
| D14 | 事件总线 | Pulsar（集群已有，不新建 Kafka） |
| D15 | 读侧分析库 | TiDB + TiFlash（集群已有，不引 ClickHouse） |
| D16 | GraphQL 层 | 自研 Go 网关（Apollo Router 形态） |
| D17 | DDD 落点 | 仅诊断/决策域厚建模，监测域薄层 |
| D18 | Rust 落地范围 | 协议解析 + DSP 核；采集代理由 Go 做 |
| D19 | 集群凭据 | 提供 `pdm` tenant 权限与中间件账号（见 docs/16 §5 的 I1 – I4） |
| D20 | 海外合规 | 原始数据本地化，仅脱敏特征值上行 |
| D21 | 汽车行业预留 | 做行业包 SPI 框架 |
| D22 | 多语言构建 | 统一流水线 + 统一质量门禁 |

> 同时需要回收 8 项待确认事实（C1 – C8）：见 `docs/14 §1.2`（基地分布、设备规模、现有 IT、EAM、供应商意愿、集团平台、海外网络、OT 清单），直接影响工期与架构。

## 5. 下一步（你确认后我才动手）

- Gate G0 方案评审：你确认 v1.0 文档 + D1 – D22 + C1 – C8，冻结 v1.0 基线。
- Ph1 起进入实现：按 `docs/10` 的数据底座开始，首期范围按 D11，每阶段交付可运行切片 + 测试报告，不搞"大爆炸交付"。
- 前置阻塞：D19（docs/16 §5 的 I1 – I4）不解决，基础设施层无法施工。

---

*本文档集为方案基线，不含实现代码。所有指标均为目标值，需在 P1 阶段用真实数据校准。*