08 · 测试与质量保证（TDD / BDD / ATDD）

项	内容
文档编号	DT-PdM-08
依据	GB/T 8567-2006 §6 测试计划；ISO/IEC/IEEE 29119（软件测试）；TDD / BDD / ATDD 实践
版本	v0.1

1. 三层驱动关系（先说清概念，避免团队各说各话）

```
ATDD  ■■■■■■■■■"■■■■■"■■■■■■■■■/■■/■■■■■■■■■■
  ■
  ■■■ BDD  ■■■■■■■■■■■■■ Gherkin■Given/When/Then■■■■■■
  ■
  ■■■ TDD  ■■■■■■■■■■■■■■■■■■■■■■■■→■→■■
```

	ATDD	BDD	TDD
粒度	特性/故事	场景	函数/类
谁写	业务+测试+开发	三方共同	开发
语言	业务语言	Gherkin	代码
频率	每特性	每场景	每次提交
本项目落点	`specs/*/spec.md` 的验收标准	`specs/*/*.feature`	`tests/unit/`

关键纪律：Gherkin 场景不是"测试脚本"，是"需求的可执行表达"。写不出场景的需求，说明需求没想清楚。

2. 测试策略

2.1 测试金字塔（本项目配比）

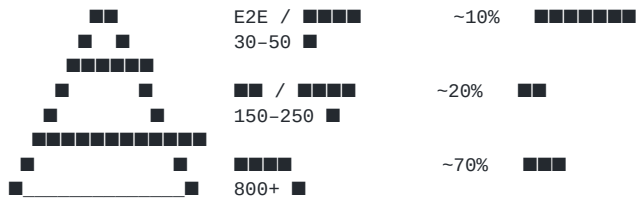

反模式警告： 不要做"冰淇淋筒"（大量 E2E + 少量单元）。工业系统的 E2E 需要真实设备，成本极高且不稳定。

2.2 特殊测试层（工业 AI 系统特有）

```
■■■■■■■■■■■■■■■■■■■
```

3. TDD 实践规范

3.1 红-绿-重构（强制）

1. ■■■■■■■■■■■—■■■■■■■■■■■■■■■■"■■■■■"■■"■■■"
2. ■■■■■■■■■■■■■■—■■"■■■■■■■"■■■
3. ■■■■■■■■—■■■■■■■■■■
4. ■■■■■■■■ ≤ 15 ■■■

3.2 单元测试要求

项	要求
命名	`test_<■■■■■>_<■■■>_<■■■>`，如 `test_hi_calculation_single_dim_fatal_returns_zero`
结构	Arrange-Act-Assert 三段，空行分隔
断言	一个测试一个概念；避免 `assert x == 1 and y == 2`
隔离	不碰网络/数据库/时间（用 fake/注入 Clock）
覆盖	行 ≥ 80%，核心算法（特征/HI/RUL）≥ 90%，分支 ≥ 75%
速度	单测全量 < 60 秒

3.3 核心算法测试样例（特征与 HI）

```
# tests/unit/test_health_index.py
import pytest
from pdm.health import compute_hi

class TestHealthIndex:
    def test_all_dimensions_healthy_returns_100(self):
        hi = compute_hi(s_vib=0.0, s_imp=0.0, s_temp=0.0, s_curr=0.0, s_trend=0.0)
        assert hi.value == 100

    def test_single_dim_fatal_forces_zero(self):
        # ■■■■■■ → ■■■■■■■■■■■
        hi = compute_hi(s_vib=1.0, s_imp=0.0, s_temp=0.0, s_curr=0.0, s_trend=0.0)
        assert hi.value == 0
        assert hi.level == "red"

    def test_missing_dimension_renormalizes_weights(self):
        hi = compute_hi(s_vib=0.5, s_imp=None, s_temp=0.0, s_curr=0.0, s_trend=0.0)
        assert hi.degraded is True
        assert abs(sum(hi.weights.values()) - 1.0) < 1e-6

    def test_contributions_sum_matches_delta(self):
        hi = compute_hi(s_vib=0.62, s_imp=0.55, s_temp=0.1, s_curr=0.0, s_trend=0.4)
        total_delta = sum(c.delta for c in hi.contributions)
        assert abs((100 + total_delta) - hi.value) < 1e-6

    @pytest.mark.parametrize("s,expected_level", [
        (0.0, "green"), (0.25, "green"),
        (0.35, "yellow"), (0.5, "orange"), (0.7, "red"),
    ])
    def test_level_boundaries(self, s, expected_level):
        hi = compute_hi(s_vib=s, s_imp=0, s_temp=0, s_curr=0, s_trend=0)
        assert hi.level == expected_level
```

3.4 测试替身策略

依赖	替身	说明
时序库	In-memory fake	固定数据集，可断言查询
LLM	Stub（录制回放）	避免测试依赖模型不确定性

依赖	替身	说明
EAM	Mock Server（WireMock）	可注入 500/超时
时钟	注入 `Clock` 接口	时间相关逻辑可测
传感器	波形回放器	用真实故障波形驱动

> LLM 测试原则： 单元测试不调真实模型。用录制的"提示→响应"对做回归；真实模型只在"AI 行为测试层"跑，且用温度 0 + 固定版本。

---

4. BDD 实践规范

4.1 Gherkin 写作规则

规则	说明
一场景一行为	不要在一个 Scenario 里验证 3 件事
Given 用业务语言	"Given 3 号压缩机已连续运行 30 天" 而非 "Given 数据库有 1000 行"
Then 可观测	必须能被外部观察到（返回值、事件、UI）
避免 UI 细节	不写"点击第 3 个按钮"，写"提交确认"
数据用表格	多组数据用 `Scenario Outline`
每条 FR 至少 1 场景	需求追踪的硬要求

4.2 核心场景（节选，完整见 `specs/*/*.feature`）

```
# language: zh-CN
■■: ■■■■■■■
  ■■■■■■■■
  ■■■■■■■■■■■■■■■■■■■
  ■■■■■■■■■■■■■

  ■■: ■■■■■■■■■■■■■
    ■■ 3 ■■■■■■■■■■■■■■■■■■■■ 11.2 mm/s
    ■■ ■■■■■ ISO 20816-3 ■ D ■
    ■ ■■■■■■■■■■■■
    ■■ ■■■■■■■ 0
    ■■ ■■■■■■■ "■■"
    ■■ ■■■■■■■■■ "ISO 20816-3 D■"

  ■■: ■■■■■■■■■■■■■■■■
    ■■ 3 ■■■■■■ 4 ■■■■■■
    ■■ ■■ 2 ■■■■■■■
    ■ ■■■■■■■■■■■■
    ■■ ■■■■■■■ "■■■■■"
    ■■ ■■■■■■■ 0.6
    ■■ ■■■■■■ "■■■■■"

  ■■■■■: ■■■■■■■
    ■■ ■■■■■■■■■ <hi>
    ■ ■■■■■■■■■
    ■■ ■■■■■■■ <level>
    ■■ ■■■■■■■ <sla> ■■

    ■■:
      | hi | level  | sla |
      | 95 | ■■   | 0   |
      | 80 | ■■   | 0   |
      | 79 | ■■   | 168 |
      | 60 | ■■   | 168 |
      | 59 | ■■   | 72  |
      | 40 | ■■   | 72  |
      | 39 | ■■   | 4   |

■■: ■■■■■■■
```

```
  ■■: ■■■■■■■■■■■■■■■■■■■■
    ■■ ■■ KA-101 ■■■■■■■■■■ 19 ■
    ■■ ■■■■■■■ 10 ■ 30 ■■■■
    ■■ 10 ■ 28 ■■■■■■■■■■
    ■ ■■■■■■■■■■
    ■■ ■■■■■■■■■■■■■■■ 2026-10-30
    ■■ ■■■■■■■■ "■■■■■■" ■■■■
    ■■ ■■■■■■ 1 ■■■■■■

  ■■: ■■■■■■■■■■
    ■■ ■■■■■■■ 10 ■ 28 ■■■■
    ■■ ■■■■■■■■■ 10 ■ 30 ■■■■■
    ■ ■■■■■■■■■■
    ■■ ■■■■■■■■■ 0.6
    ■■ ■■■■■■■■ "■■■■■■■■■■■"
    ■■ ■■■■■■■■ "■■■■■■"

■■: ■■■■■■
  ■■: ■■■■■■■■■■■■■■■■
    ■■ ■■■■■■■■■■■■ REC-20261021-0031
    ■■ ■■■■■■■■■■■■■■
    ■ ■■■■■■ "■■■■■■■" ■■
    ■■ ■■■■■■■
    ■■ ■■■■■■■ "PDM-3002"
    ■■ ■■■■■■■■■■■■■■■■■■

  ■■: ■■■■■■■■■■■■■■■■
    ■■ ■■■■■■■ "■■■■■■■" ■■■■■■
    ■ ■■■■■■ "■■■■■■"
    ■■ ■■■■■■■■■■■
    ■■ ■■■■■■ "■■■■■■■■■■■■■"
    ■■ ■■■■■■■
```

4.3 BDD 执行架构

```
.feature ■■■■■■■■■
      ■
      ▼
step definitions■Python: pytest-bdd■
      ■
      ▼
■■■■■■API / MCP ■■■ / UI ■■■
      ■
      ▼
■■■■■■Docker Compose■TDengine + PG + mock EAM + stub LLM■
```

规则： 场景只通过外部接口驱动系统，不直接调内部函数（否则就是伪装的单元测试）。

---

5. ATDD：验收标准前置

5.1 三方评审（Three Amigos）

每个特性开发前，业务（设备专家）、开发、测试三方 45 分钟会议，产出：

- 这个特性不做什么（边界）
- 3 – 5 条验收场景（Gherkin 草稿）
- 需要的数据样本（真实波形/工单）
- 无法自动化的部分（人工验收项）

没有三方评审的特性，不允许进入开发。

5.2 验收标准模板

```
## ■■■XXX
### ■■■■
■■■■■■■■■■■■■

### ■■■■
```

```
- [ ] AC-1: ■Gherkin ■■■■■
- [ ] AC-2: ...
- [ ] AC-3: ■■■■■■■■■■■■■■■■■■■■
```

```
### ■■■■
- ■■ ...
- ■■ ...

### ■■■■
- ■■ 3 ■■■■■■■■■■■■■■■
```

---

6. 模型评测（第 6 层，最容易糊弄也最不能糊弄）

6.1 评测数据集

集	内容	规模	用途	更新
Golden Set	已拆检确认的故障案例	≥ 60	验收、回归	季度
Replay Set	连续 3 个月全量	20 台	误报率	月度
OOD Set	工况越界	≥ 30	鲁棒性	半年
Synthetic	注入故障	不限	冷启动	按需

6.2 指标定义（必须写清公式，避免各说各话）

指标	定义	目标		
召回率 Recall	TP / (TP + FN)，按故障模式分别算	≥ 90%（关键模式）		
误报率 FPR	FP / (FP + TN)，按"设备 · 周"统计	≤ 0.5 次/台 · 周		
提前期 Lead Time	首次橙色 → 实际失效的天数	中位数 ≥ 14 天		
RUL MAE	mean(|	pred − actual|	) / actual	≤ 20%
区间覆盖率	实际值落在 [P10,P90] 的比例	75% – 85%		
校准误差 ECE	置信度分箱后 |	acc − conf|	加权和	≤ 0.08
降级正确率	数据不足时正确标记降级的比例	≥ 95%		

> 为什么要求区间覆盖率 75 – 85% 而不是 100%： 100% 说明区间过宽（没有信息量）；低于 70% 说明区间不可信。80% 名义区间实际覆盖 75 – 85% 才算校准良好。

6.3 评测报告模板

```
# ■■■■■■■ v{■■}
## 1. ■■■■■
■■ / ■■ / ■■■■■■ / ■■ commit

## 2. ■■■■■
■■■■■■■/■■/■■■/RUL MAE/ECE■

## 3. ■■■■■■■■
■■■■■■■■■■■■■■■■■■ 3 ■■

## 4. ■■■■■■■
■■■ 5 ■■■■■■■■■■■■■■
```

```
## 5. ■■■■■■
■■■■■■■■■■■■■■■■■■■

## 6. ■■■■■■
■■■■■■■ / ■■■■■ / ■■■■■■■■■
```

硬性要求：报告必须包含"失效案例"，只有好指标的评测报告一律打回。

---

7. 混沌与降级测试（第 4 层）

7.1 故障注入清单

#	注入	期望行为	验证点
C1	断网 30 分钟	边缘继续诊断与告警	本地告警正常，恢复后补传
C2	单通道拔除	降级 + 置信度下调	不输出"正常"
C3	时钟跳变 +5 分钟	检测并标记	不产生错误趋势
C4	数据冻结（值不变）	识别为 STALE	不当作"稳定健康"
C5	波形丢包 20%	质量分下降，仍可分析	置信度下降
C6	PLC 拒绝连接	重连退避，其他设备不受影响	隔离性
C7	LLM 服务超时	降级到模板报告	仍输出建议动作
C8	EAM 返回 500	重试 3 次 → 人工队列	不声称成功
C9	磁盘写满	按优先级淘汰波形	结论不丢
C10	Kafka 堆积 100 万条	背压 + 告警	不 OOM

7.2 混沌测试执行

```
# chaos/experiments/network-partition.yaml
name: edge-network-partition
target: edge-node-01
action: partition
duration: 30m
direction: to-center
assertions:
  - local_diagnosis_available: true
  - alerts_delivered_locally: true
  - cache_size_growth: "< 20GB"
  - recovery_backfill_complete: "within 5m"
```

频率： 每迭代 1 次（非生产环境）；上线前 1 次（准生产）。

---

8. 性能测试（第 3 层）

场景	负载	通过标准
采集吞吐	5,000 点/秒 × 60 分钟	零丢点，CPU < 70%
特征计算	100 并发波形	P95 < 500 ms
诊断 API	50 并发	P95 < 8 s，错误率 < 1%
会诊	10 并发	P95 < 60 s
看板	50 用户	首屏 < 2 s
长稳	72 小时	内存无泄漏（增长 < 5%）

---

9. 质量门禁（Quality Gates）

Gate	条件	阻断
G-提交	单测通过 + Lint 通过 + 覆盖率不下降	阻断合并
G-合并	单测 ≥ 80% + 契约测试通过 + SAST 无高危	阻断合并
G-构建	镜像扫描无高危 + SBOM 生成	阻断部署
G-集成	BDD 场景 100% 通过 + 混沌 C1 – C3 通过	阻断进准生产
G-发布	性能达标 + 模型评测达标 + 安全测试通过	阻断上线
G-灰度	灰度 7 天误报率达标 + 无 P1 事件	阻断全量

9.1 Definition of Done（DoD）

一个特性"完成"必须同时满足：

- [ ] 代码已合并主干
- [ ] 单元测试覆盖（含边界与异常）
- [ ] 对应 Gherkin 场景通过
- [ ] 契约测试通过（如有接口变更）
- [ ] 文档更新（接口文档/ADR/运维手册）
- [ ] 可观测性埋点（日志/指标/trace）
- [ ] 已在测试环境演示给业务方
- [ ] 无新增技术债（或有登记）
- [ ] 回滚方案明确

"能跑"不是完成，"能回滚、能观测、能解释"才是完成。

---

10. 缺陷分级与响应

级别	定义	响应	修复
P0	数据错误导致误判停机 / 越权 / 数据外泄	15 分钟	4 小时
P1	核心功能不可用（诊断不出结果）	1 小时	24 小时
P2	功能异常但有绕过方案	4 小时	3 天
P3	体验/文案/非关键	1 天	下迭代

P0 定义里"误判停机"排第一——因为一次错误的"建议停机"造成的损失，可能超过系统全年收益。

---

11. 测试环境矩阵

环境	用途	数据	模型	设备
dev	开发自测	合成	stub	模拟器
ci	自动化	固定夹具	stub	无
test	集成/BDD	脱敏真实（1 个月）	真实（小模型）	波形回放
staging	准生产/性能/混沌	脱敏真实（3 个月）	真实（全量）	1 台真实设备
prod	生产	真实	真实	全部

staging 必须有 1 台真实设备。 纯回放的测试环境，永远测不出"传感器松动"这类物理问题。