# 09 · DevOps 交付流水线与工程规范

| 项 | 内容 |
| --- | --- |
| 文档编号 | DT-PdM-09 |
| 依据 | Harness.io（CI/CD 平台）；GitOps（ArgoCD）；SLSA 供应链安全；GB/T 8567 配置管理 |
| 版本 | v0.1 |

> 再次澄清：本文的 Harness 指 Harness.io 软件交付平台；智能体运行时工程见 `docs/05`。

## 1. 交付流水线总览

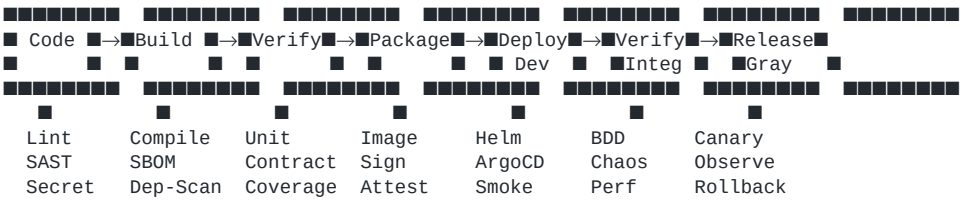


核心原则：

- 一切皆代码（流水线、环境、配置、判据、提示词、技能）
- 制品不可变（镜像 digest 引用，不用 tag）
- 环境晋升而非重建（同一制品从 dev → staging → prod）
- 每次变更可回滚（< 15 分钟）

## 2. Harness.io 流水线设计

### 2.1 流水线清单

| 流水线 | 触发 | 阶段 | 时长目标 |
| --- | --- | --- | --- |
| `pr-verify` | PR 创建/更新 | Lint → SAST → Unit → Contract | ≤ 8 min |
| `main-build` | 合并主干 | Build → SBOM → 镜像 → 签名 → 推送 | ≤ 12 min |
| `deploy-dev` | 构建成功 | Helm 部署 dev → 冒烟 | ≤ 5 min |
| `verify-integration` | dev 部署成功 | BDD → 混沌 C1 – C3 → 性能基线 | ≤ 30 min |
| `deploy-staging` | 集成通过 | 部署 staging → 全量回归 | ≤ 40 min |
| `release-canary` | 人工批准 | 灰度 5% → 观测 24h → 25% → 100% | 按策略 |
| `rollback` | 手动/自动 | 回滚到上一 digest | ≤ 5 min |

### 2.2 关键阶段配置（示例）

```
# .harness/pipelines/pr-verify.yaml
pipeline:
  name: pr-verify
```

```
stages:
  - stage: static
    steps:
      - run: ruff check . && mypy src/
      - run: bandit -r src/ -ll
      - run: gitleaks detect --no-git
  - stage: test
    steps:
      - run: pytest tests/unit --cov=src --cov-fail-under=80
      - run: pytest tests/contract
  - stage: security
    steps:
      - run: trivy fs --severity HIGH,CRITICAL --exit-code 1 .
```

### 2.3 质量门禁（阻断式）

| 门禁 | 阈值 | 阻断点 |
|---|---|---|
| 单测覆盖率 | < 80% | PR 合并 |
| 覆盖率下降 | 任意下降 | PR 合并 |
| SAST 高危 | > 0 | PR 合并 |
| 密钥泄露 | > 0 | PR 合并（并告警） |
| 依赖漏洞 CVSS ≥ 7 | > 0 未修复 | 构建 |
| 镜像高危 | > 0 | 部署 |
| BDD 失败 | > 0 | 进 staging |
| 性能回退 | P95 劣化 > 20% | 进 staging |
| 模型评测回退 | 召回下降 > 3% 或误报上升 > 50% | 上线 |

> "模型评测回退"是 AI 项目特有的门禁。没有它，模型迭代就是开盲盒。

---

## 3. 仓库结构（Monorepo + 独立部署）

```
diting-pdm/
■■■ README.md
■■■ docs/                          # ■■■■
■   ■■■ adr/                       # ■■■■■■■
■   ■■■ ...
■■■ specs/                         # SDD ■■■■■■■■■■
■   ■■■ constitution.md
■   ■■■ 001-■■■■■■■/
■   ■   ■■■ spec.md
■   ■   ■■■ plan.md
■   ■   ■■■ tasks.md
■   ■   ■■■ features/*.feature
■   ■■■ 002-■■■■■■■/
■■■ services/
■   ■■■ ingest-gateway/            # Go
■   ■■■ feature-engine/            # Python
■   ■■■ diagnosis-engine/          # Python
■   ■■■ prognosis-engine/          # Python
■   ■■■ agent-runtime/             # Python■Harness■
■   ■■■ mcp-server/                # Python
■   ■■■ decision-service/          # Python
■   ■■■ alert-service/             # Go
■   ■■■ integration-eam/           # Python
■   ■■■ audit-service/             # Go
■■■ packages/
■   ■■■ pdm-core/                  # ■■■■■■■■■■■■■
■   ■■■ pdm-signal/                # ■■■■■■■■■■■
■   ■■■ pdm-testkit/               # ■■■■■■■■■■■
■■■ deploy/
■   ■■■ helm/                      # Chart
■   ■■■ k8s/                       # ■■■■■
■   ■■■ edge/                      # K3s ■■■■■
■   ■■■ argocd/                    # GitOps Application
■■■ tests/
```

```
■   ■■■ unit/  integration/  e2e/  contract/  chaos/  perf/  security/
■■■ datasets/                    # DVC ■■■■■■ Git
■■■ models/                      # ■■■■■■■■■■■■
■■■ .harness/                    # ■■■■■■
```

为什么 Monorepo： 契约（`pdm-core`）变更需要原子性；6 人团队拆多仓的管理成本高于收益。

---

# 4. 环境与配置管理

## 4.1 环境矩阵

| 环境 | 集群 | 数据 | 模型 | 访问 |
|---|---|---|---|---|
| dev | 单节点 K3s | 合成 | stub | 开发 |
| ci | 临时 | 夹具 | stub | 流水线 |
| test | 3 节点 | 脱敏 1 月 | 小模型 | 团队 |
| staging | 3 节点 | 脱敏 3 月 | 全量 | 团队 + 业务 |
| prod | 生产 | 真实 | 全量 | 受控 |

## 4.2 配置分层

```
■■■■■■■■■■
  ■■ ■■■■■■deploy/values-{env}.yaml■
       ■■ ■■■■■■ConfigMap■■■■■■■
            ■■ ■■■■■■■Feature Flag■■■■■■
```

规则： 判据阈值、提示词、技能版本 不属于配置，属于"受控资产"，必须走变更审批（见 docs/07 §5.3）。

## 4.3 密钥管理

| 项 | 方案 |
|---|---|
| 存储 | Vault / K8s Secret（加密 etcd） |
| 注入 | 运行时挂载，不写镜像 |
| 轮换 | 90 天自动 |
| 审计 | 每次读取记录 |
| 禁止 | 硬编码、日志打印、异常堆栈泄露 |

---

# 5. GitOps（ArgoCD）

```
Git■deploy/■  ←■■ ArgoCD ■■■■■ ■■→  K8s ■■
      ■                                ■
      ■■■ ■■■■■■                       ■■■ ■■■■■■■■■■■
```

| 规则 | 说明 |
|---|---|
| 禁止 `kubectl apply` 手工改生产 | 所有变更走 Git |
| 禁止 `latest` tag | 用 digest |
| 漂移检测 | 每 3 分钟，漂移 > 5 分钟告警 |
| 同步策略 | staging 自动；prod 手动批准 |
| 回滚 | `argocd app rollback` 或 Git revert |

## 5.1 边缘节点更新策略（关键差异）

边缘不能像中心一样"随时滚"：

```
1. ■■■■ → ■■■■■■■■■■■■■■■■■■
2. ■■■■■■■■■■■■■■■■■
3. ■■■■■■■■■■ 2-4 ■■■■■
4. ■■■■■■■ → ■■ 1 ■ → ■■ 24h → ■■
5. ■■■■■■■■■■■■■■■■■ 2 ■■■■■
```

边缘更新必须"拉"不能"推"——工厂网络经常反向不通。

---

# 6. 可观测性

## 6.1 三大支柱

| 支柱 | 工具 | 关键内容 |
| --- | --- | --- |
| Metrics | Prometheus + Grafana | 采集速率、诊断时延、HI 分布、告警量、token 成本 |
| Logs | Loki | 结构化 JSON，trace_id 贯穿 |
| Traces | OTel + Tempo/Jaeger | 一次诊断的完整调用链 |

## 6.2 必埋指标（Golden Signals + AI 特有）

| 类别 | 指标 |
| --- | --- |
| 延迟 | 诊断 P50/P95/P99、工具调用耗时、LLM 首 token 时延 |
| 流量 | 采集点/秒、诊断 QPS、MCP 调用/分钟 |
| 错误 | 工具失败率、LLM 超时率、EAM 失败率 |
| 饱和 | CPU/内存/磁盘/队列深度 |
| AI 特有 | token/次、成本/次、缓存命中率、工具选择错误率、降级触发次数、假完成拦截次数 |
| 业务 | 告警量/天、工单转化率、方案卡采纳率、误报率 |

## 6.3 SLO

| SLI | SLO | 错误预算 |
| --- | --- | --- |
| 诊断 API 可用性 | 99.5%/月 | 3.6 小时 |
| 诊断 P95 时延 | ≤ 8 s | 5% 请求可超 |
| 告警送达时延 | ≤ 60 s | 1% 可超 |
| 数据完整率 | ≥ 99.5% | — |

错误预算耗尽 → 冻结功能发布，只修稳定性。 这是 SRE 的硬规则。

---

# 7. 发布策略

## 7.1 中心侧：金丝雀

```
5% ■■■1 ■■→ 25%■1 ■■→ 100%
■■■■■■■■■■■■■P95■■■■■■
■■■■■■■ → ■■■■
```

## 7.2 边缘侧：分批

1 ■■72 ■■■→ 1 ■■■■1 ■■→ ■■

边缘灰度时间必须更长——因为边缘故障的影响是"这台设备没人看着了"，而不是"页面打不开"。

### 7.3 模型发布（特殊）

| 步骤 | 要求 |
|---|---|
| 影子模式 | 新模型并行跑 2 周，只记录不生效，对比差异 |
| 小流量 | 10% 设备 |
| 人工复核 | 新模型的所有橙色以上告警，前 100 条人工复核 |
| 全量 | 无异常后 |
| 回滚 | 保留上一版本，一键切换 |

---

## 8. 供应链安全（SLSA Level 3 目标）

| 要求 | 实现 |
|---|---|
| 构建可复现 | 固定基础镜像 digest、锁定依赖（lock 文件） |
| 构建隔离 | 流水线在隔离 runner 执行 |
| 来源证明 | 生成 SLSA provenance |
| 制品签名 | cosign（keyless，OIDC） |
| 部署校验 | 准入控制器验证签名，未签名镜像拒绝 |
| SBOM | Syft 生成，随制品归档 |
| 依赖审计 | 每周生成漏洞报告 |

---

## 9. 配置管理（GB/T 8567 要求）

| 配置项 | 标识规则 | 基线 |
|---|---|---|
| 源码 | Git commit SHA | 每次发布打 tag `v{major}.{minor}.{patch}` |
| 镜像 | `registry/pdm/{svc}@{sha256}` | 随发布 |
| Helm Chart | 语义化版本 | 随发布 |
| 模型 | `{name}-{version}-{dataset_hash}` | 模型注册表 |
| 判据库 | `criteria-v{n}` | 每次变更 |
| 提示词 | `prompt-v{n}` | 每次变更 |
| 技能 | `skill-{name}-v{n}` | 每次评审通过 |
| 文档 | 与代码同仓 | 随发布 |

三库分离原则：代码库（Git）、模型库（Registry）、数据湖（对象存储）各自版本化，通过指纹关联。

---

## 10. 团队协作规范

| 实践 | 规则 |
| --- | --- |
| 分支 | 主干开发 + 短分支（≤ 2 天） |
| 提交 | Conventional Commits（feat/fix/docs/refactor/test/chore） |
| PR | ≤ 400 行；必须 1 人 review；必须过 CI |
| Code Review | 关注：边界条件、错误处理、可观测性、安全 |
| 每日 | 15 分钟站会（只讲阻塞） |
| 每周 | 技术债梳理 30 分钟 |
| 每迭代 | 回顾 + 1 个改进项落地 |

### 10.1 AI 辅助编码的纪律（SDD 配套）

本项目大量使用 AI 编码工具，必须遵守：

- 先规格后代码：没有 `spec.md` 不允许让 AI 生成实现。
- AI 生成代码视同外包代码：必须 review、必须测试、必须能解释。
- 禁止 AI 直接改判据/提示词/技能（这些是受控资产）。
- 提交信息注明 AI 参与度（`assisted-by: copilot`），便于追溯。
- 禁止把生产数据贴进外部 AI 工具。

> 这 5 条不是保守，是 2026 年企业级 AI 编码的真实教训：AI 让写代码变快，让"理解代码"变慢。规格是唯一能对抗这种熵增的东西。