20 · 集群重构 ADR-018：Deployment → StatefulSet，local-path → 专用本地 PV

项	内容
文档编号	DT-PdM-20
类型	架构决策记录（ADR-018）
触发	"TiKV 是 Deployment 无稳定身份；PV 是 local-path 10Gi 不可扩容"
结论	手工 StatefulSet + 静态本地 PV（离线环境最优解），已完成切换并验证
日期	2026-10-21

1. 问题定义

#	问题	后果
P1	PD/TiKV 是 3 个独立 Deployment	Pod 重建后名字变化（带 hash），PD 中残留旧 store 记录；无法按序号扩缩容；无法做有序滚动升级
P2	全部 PVC 为 `local-path` 10Gi	写满即故障；`ALLOWVOLUMEEXPANSION=false`，无法在线扩容
P3	TiFlash 无资源限制（已修）	曾把节点内存吃满
P4	集群无外网、本地仓库只有 TiFlash 镜像	无法安装 TiDB Operator

2. 方案对比

方案	是否可行	评价
A. TiDB Operator（官方推荐）	✗ 不可行	需要 `pingcap/tidb-operator` 镜像 + CRD chart，服务器无外网、本地仓库无该镜像。这是最佳方案，但环境不允许
B. 手工 StatefulSet + 静态本地 PV	✓ 采用	完全离线可实施；用现成镜像；身份稳定；存储独立规划
C. 换 NFS 存储类	⚠ 部分	可扩容，但 TiKV 对网络存储的写放大与延迟敏感，不推荐做主存储
D. 保持现状只扩容量	✗	治不了"无稳定身份"，且 local-path 不能扩

> 诚实说明：B 不是理论最优，是约束最优。一旦具备外网/镜像同步条件，应迁移到 TiDB Operator（见 §7）。

3. 存储规划（3T 怎么用）

实测磁盘：

节点	设备	挂载	容量	可用
master	vda 500G	`/home`	418G	95G
worker1	vda 1T + vdb 2T	`/home`	3.0T	2.3T

分配（全部在 worker1，`/home/k8s-data/pdm-ssd/`）：

用途	数量	单盘	小计	说明
TiKV 数据	3	200Gi	600Gi	单副本 200Gi，三副本各存全量
PD 数据	3	20Gi	60Gi	元数据，实际占用很小
TiFlash 列存	1	100Gi	100Gi	分析加速，可重建
合计			760Gi	剩余约 1.5T 余量

3.1 为什么"扩容"不该靠扩 PVC

TiKV 是分片（Region）+ Raft 多副本架构。容量不足时的标准做法是：

```
■■■ → ■ PV → ■ TiKV ■■■ → PD ■■■ Region ■■■■■■■
```

而不是"把某个 PVC 从 200Gi 改到 500Gi"。后者在本地盘上根本做不到（local PV 不支持扩容），在云盘上也只是把单点做大。

所以"数据涨了只能重建"这个担忧，正确解法是横向扩容，而不是纵向扩盘。我们预留 200Gi/副本 + 1.5T 余量，足够支撑到需要加第 4 个 TiKV 的时间点。

3.2 为什么全放 worker1

- master 只剩 95G，放不下 200Gi 的 TiKV；
- 两节点集群本来就无法做到节点级高可用（3 副本里挂 1 个节点就丢 2 副本，无 quorum）；
- 与其做"看起来分散"的伪高可用，不如老实承认限制，并把扩容路径写清楚。

> 真 HA 的前提是第 3 个节点。这条已写入遗留项。

---

4. 实施步骤

```
# 1) ■■■ StorageClass
mkdir -p /home/k8s-data/pdm-ssd/{tikv-0,tikv-1,tikv-2,pd-0,pd-1,pd-2,tiflash-0}
kubectl apply -f 01-storage.yaml     # SC + 7 ■ PV + pd-peer/tikv-peer

# 2) ■■■■■■■■■■■■■
for d in pd-0 pd-1 pd-2 tikv-0 tikv-1 tikv-2 tidb tiflash; do
  kubectl -n infra scale deploy/$d --replicas=0
done

# 3) ■■ PVC■■■■ region_size = 0■■■■■■
kubectl -n infra delete pvc tikv-{0,1,2}-data pd-{0,1,2}-data tiflash-data

# 4) ■■■■
kubectl apply -f 02-workload.yaml     # pd/tikv StatefulSet + tidb-server Deployment

# 5) ■■■■■■■■■■■■ DNS ■■■
kubectl -n infra patch svc pd-0 -p '{"spec":{"selector":{"app":"pd","statefulset.kubernetes.io/pod-name":"pd-0"}}}'
```

关键设计点：

点	做法	原因
稳定 DNS	headless `pd-peer` / `tikv-peer` + `publishNotReadyAddresses: true`	Raft 组建期 Pod 尚未 Ready，必须能互相解析
PD 引导	`--initial-cluster` 写全 3 个 peer URL	首次启动组建集群；已有数据时自动忽略
存储绑定	`volumeBindingMode: WaitForFirstConsumer`	保证 PV 与 Pod 调度到同一节点
回收策略	`Retain`	误删 PVC 不丢数据
优先级	`pdm-data-critical`	资源紧张时最后被驱逐
宽限期	300s	给 TiKV 腾 leader 留时间（详见 docs/18）

---

5. 踩坑记录（三个，都是真踩的）

#	现象	原因	修复
1	PD `CrashLoopBackOff`，日志 `log directory shouldn't be the subdirectory of data directory`	我加了 `--log-file=/data/pd.log`，而 `/data` 是数据目录	去掉该参数，日志走 stdout
2	TiDB `RunContainerError: exec: "--store=tikv": executable file not found`	`pingcap/tidb` 镜像没有 ENTRYPOINT，只给 args 会被当成 command	显式 `command: ["/tidb-server"]`
3	TiFlash 恢复后连不上 PD	其 init 脚本把 PD 地址写死为 `pd-0.infra.svc...`（旧的每 Pod 无头服务），而新 PD 在 `pd-0.pd-peer...`	把旧服务 `pd-0/1/2`、`tikv-0/1/2` 的 selector 改为 `statefulset.kubernetes.io/pod-name`，保持 DNS 名称不变

第 3 条是这次最有价值的经验：迁移时不要急着改别人的引用，先把旧名字指到新对象上。

---

6. 验证结果

检查	结果
PD	`pd-0/1/2` 全部 1/1 Running（StatefulSet，稳定序号名）
TiKV	`tikv-0/1/2` 全部 1/1 Running，PD 中 stores count = 3，地址为 `tikv-N.tikv-peer...`
TiDB	`tidb-server` 2 副本 Running
TiFlash	1/1 Running，绑定 100Gi 新 PV

检查	结果
PVC	7 个全部 Bound：tikv 200Gi ×3、pd 20Gi ×3、tiflash 100Gi
SQL	通过 NodePort 30210 连接成功，`select version()` → `8.0.11-TiDB-v8.5.8`
库表	`pdm` 库 16 张表创建成功
权限	`pdm_diag` 账号可读写，DDL 被拒绝（符合 TENANT_ISOLATION §6）

---

7. 遗留与后续

#	项	影响	计划
R1	PD 的 PVC 与 PV 序号错位（`data-pd-0` 绑到 `pdm-pd-2`）	无功能影响（同规格同节点），但运维时容易看错	加 PV 标签 + `selector` 精确绑定，下次重建时处理
R2	两节点无法真正高可用	挂 worker1 即全库不可用	建议加第 3 个节点；或用 NFS/分布式存储做跨节点副本
R3	TiFlash 仍是 Deployment（单副本）	身份不稳定，但 TiFlash 无 Raft 身份，可接受	保持现状，注释说明
R4	未使用 TiDB Operator	缺自动扩缩容、滚动升级编排	具备外网后按 §7.1 迁移
R5	无备份	事故无法恢复（违反 P5 前置条件）	部署 BR 定时备份到 MinIO

7.1 未来迁移到 TiDB Operator 的路径

```
1. ■■■■■■■■■■■■ pingcap/tidb-operator:v1.6.x■
2. helm install tidb-operator■CRD + controller■
3. ■■ TidbCluster■■■ name■■■■■■■
4. Dumping ■■ → Lightning ■■■■ BR ■■■■■■
5. ■■ Service selector
6. ■■■■ StatefulSet
```

因为数据层已经用标准 StatefulSet + 标准镜像，迁移成本主要是"数据搬迁"，不涉及应用改造。

---

8. 对项目的影响

项	变化
`docs/17` D23（全用 TiDB）	前置条件 P1/P2 已满足：OOM 已修（docs/18）、存储已扩到 200Gi/副本
`docs/16` 复用矩阵	TiDB 从"有条件复用"升级为"可用于生产主库"（R2 除外）
`impl/db/tidb`	建表脚本已在真实集群执行，16 张表可用
部署清单	新增 `impl/deploy/k8s/tidb-cluster.yaml`，纳入版本管理