SPEC-001 技术方案（Plan）

项	内容
关联	`spec.md`
状态	Draft
预计工作量	8 人日（平台 3 / 算法 3 / 前端 2）

---

1. 架构落点

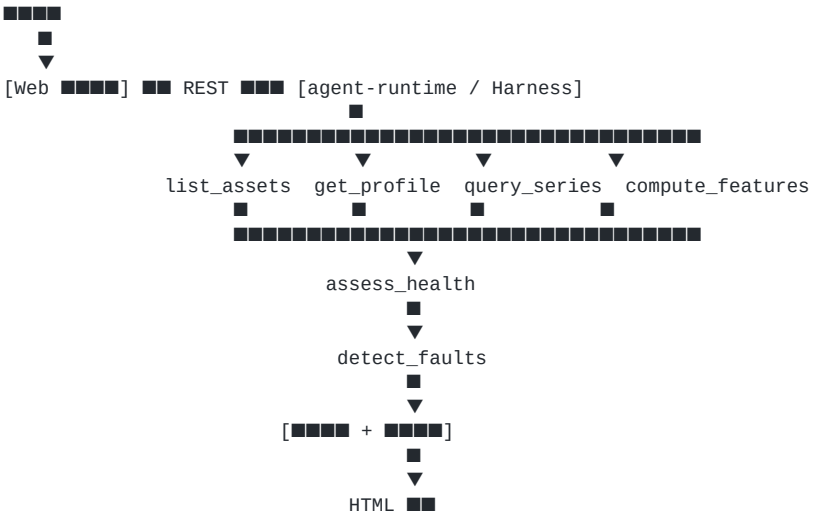

只读工具链，零写操作。 权限模型里全部 ALLOW。

---

2. 关键技术决策

决策	选择	理由	备选
意图解析	LLM 结构化输出（JSON Schema 约束）	灵活、可扩展	正则/规则（太脆）
设备消歧	先精确匹配位号 → 再模糊匹配 → 最后候选列表	避免"3号电机"匹配错	纯向量检索（不准）
工具编排	固定 DAG（非自由循环）	可预测、可测试	自由 ReAct（不稳定）
证据组装	工具返回的 `evidence` 字段汇总去重	强制契约	事后提取（易漏）
报告	服务端渲染 HTML（Jinja + ECharts CDN 内联）	可离线、可归档	前端渲染（不可归档）
缓存	设备档案 10 min；健康结果 5 min	减少重复计算	不缓存（成本高）

2.1 为什么用固定 DAG 而不是自由 ReAct

首期只有 6 个只读工具，路径高度确定：

■■ → ■■■ → ■■■ → ■■■ → ■■■■ → ■■■■ → ■■

固定 DAG 的好处：

- 每步可单独测试（TDD 友好）
- 时延可预测（≤ 8 s）
- 出错点明确
- token 消耗稳定（≈ 8k）

代价： 灵活性低。当工具增加到 10+ 或需要条件分支时，再引入受控的 ReAct（带 max_turns=6）。这个演进点写在 ADR-009。

---

3. 接口契约

3.1 主入口

```
POST /api/v1/qa
{
  "question": "3■■■■■■■■■",
  "session_id": "s-123",
  "context": {"asset_hint": null, "window": null}
}
→ 200
{
  "answer": "...",
  "level": "orange",
  "hi": 47,
  "evidence": [{"id":"EV-001","type":"series","desc":"...","value":"..."}],
  "actions": ["..."],
  "report_url": "/reports/...",
  "meta": {"elapsed_ms": 3200, "degraded": false, "trace_id": "..."}
}
```

3.2 澄清响应

```
→ 200
{
  "need_clarify": true,
  "question": "■■■■■■■■■",
  "candidates": [{"id":"KA-101","name":"3■■■■"}, ...],
  "round": 1
}
```

`round` 字段必须返回，前端据此在第 2 轮后强制给出候选列表（对应 FR-001-02）。

---

4. 数据模型（本 spec 用到）

表	用途
`asset`	设备台账
`component`	部件
`measurement_point`	测点
`series_*`（TDengine 超级表）	时序
`fault_mode`	故障模式
`diagnosis`	诊断记录（本 spec 只写这一张）
`audit_log`	审计

---

5. 实现步骤（Task 分解见 tasks.md）

步	内容	产出
1	定义 JSON Schema（意图/设备/时间窗）	`schemas/intent.json`
2	实现设备消歧（3 级匹配）	`resolver.py` + 单测
3	实现 DAG 编排器	`pipeline.py` + 单测
4	实现证据组装器	`evidence.py` + 单测
5	接入 6 个只读工具	`tools/*.py`
6	报告渲染	`report/template.html.j2`
7	对话 UI	React 组件
8	BDD 场景	`features/qa.feature`
9	注入防护	`guard/`
10	端到端联调 + 性能	测试报告

---

6. 风险

风险	影响	对策
设备名口语化（"三号机"、"3#"）	消歧失败	别名表 + 拼音/数字归一化
时序数据不足 30 天	基线学不出来	用"绝对阈值模式"降级，标注"基线未建立"
LLM 输出 JSON 不稳定	解析失败	JSON Schema 约束 + 重试 1 次 + 规则兜底
报告渲染慢（大图）	超时	图片服务端预渲染为 PNG，HTML 内联 base64

---

7. 完成定义（DoD）

- [ ] 8 条 AC 全部通过
- [ ] 单测覆盖率 ≥ 85%
- [ ] BDD 场景 100% 通过
- [ ] 100 条测试集意图识别 ≥ 95%
- [ ] P95 ≤ 8 s
- [ ] 单次成本 ≤ ¥0.3
- [ ] 注入红队 10 例全过
- [ ] 报告可离线打开（无外网依赖）